Aprendizado de máquina interpretável na análise de assinaturas mitocondriais em Cell Painting

Mario Costa Cruz

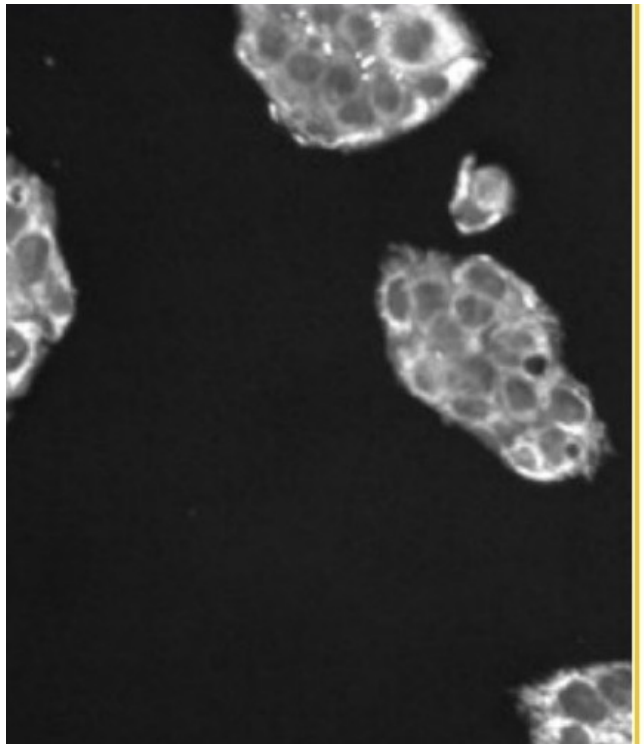
Orientador: Diego Pedroso dos Santos

MBA em Data Science e Analytics · 2026

A pergunta biológica

Podemos reconhecer uma assinatura predominantemente mitocondrial que…

1. se repita entre réplicas?
2. se conserve entre locais?
3. possa ser prevista a partir de outra réplica?



A pergunta não é “a mitocôndria mudou?”.
É: “o padrão é específico, repetível e previsível?”

Das imagens ao perfil fenotípico



intensidade • textura • granularidade • forma • distribuição espacial

EU-OPENSCREEN bioactives • HepG2 • 4 locais: IMTM, FMP, MEDINA, USC • 4 réplicas: R1–R4

32.131 perfis agregados por poço analisados no conjunto multi-institucional

O objeto de análise é o perfil: uma representação quantitativa de milhares de propriedades celulares.

A análise foi organizada como uma sequência de perguntas

1

Tornar medidas comparáveis

DMSO + seleção

2

Resumir magnitude e direção

RMS / P95 / cosseno

3

Testar repetição e estrutura

R4 + K-means + locais

4

Predizer e interpretar

XGBoost + SHAP

Cada método entra porque responde a uma pergunta específica — não porque faz parte de um “pipeline padrão”.

Primeiro: criar uma referência local

$$\frac{x - \text{mediana(DMSO)}}{1{,}4826 \times \text{MAD(DMSO)}}$$

por placa e réplica

Depois, retiramos redundância

|Spearman| < 0,90

R1–R3: desenvolvimento e seleção → R4: avaliação adicional da regra

sem imputação na normalização • R4 não selecionou características nem candidatos

A intenção é comparar desvios em relação aos controles — não comparar valores brutos entre placas.

Depois: transformar centenas de medidas em três decisões

RMS

$\sqrt{\text{média}(z^2)}$

Quanto o bloco mudou?

P95

A = RMS / P95

Mudou além dos controles?

Cosseno

cos > 0

As réplicas apontam na mesma direção?

Magnitude, referência e direção são perguntas diferentes — por isso usamos três medidas complementares.

A regra de prioridade buscou predominância, não apenas intensidade

Mito > 1 em ≥ 2 réplicas

+ demais blocos ≤ 1
+ cosseno positivo

IMTM	FMP	MEDINA	USC
12	3	0	71

A lista muda muito entre locais.

Excedência mitocondrial é frequente; predominância mitocondrial estrita é muito mais rara e dependente do local.

K-means: a estrutura se repete entre réplicas?

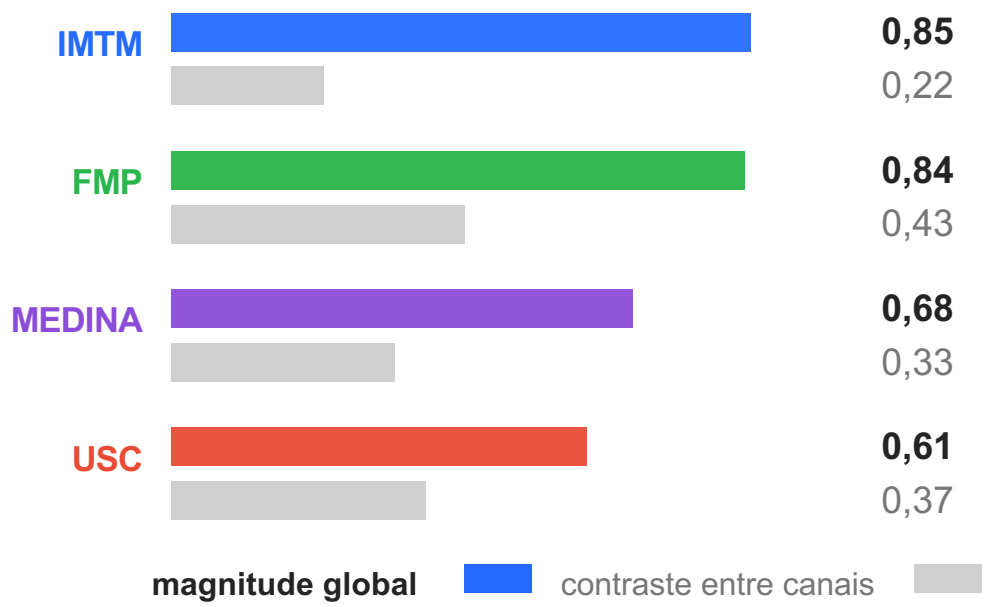
Como foi testado

k = 2–8 melhor silhouette

30 inicializações por solução

20 × 80% subamostras para estabilidade

Estabilidade entre réplicas (ARI)



A magnitude global formou agrupamentos mais reprodutíveis entre réplicas do que os contrastes entre canais.

R4: a classificação estrita reaparece?

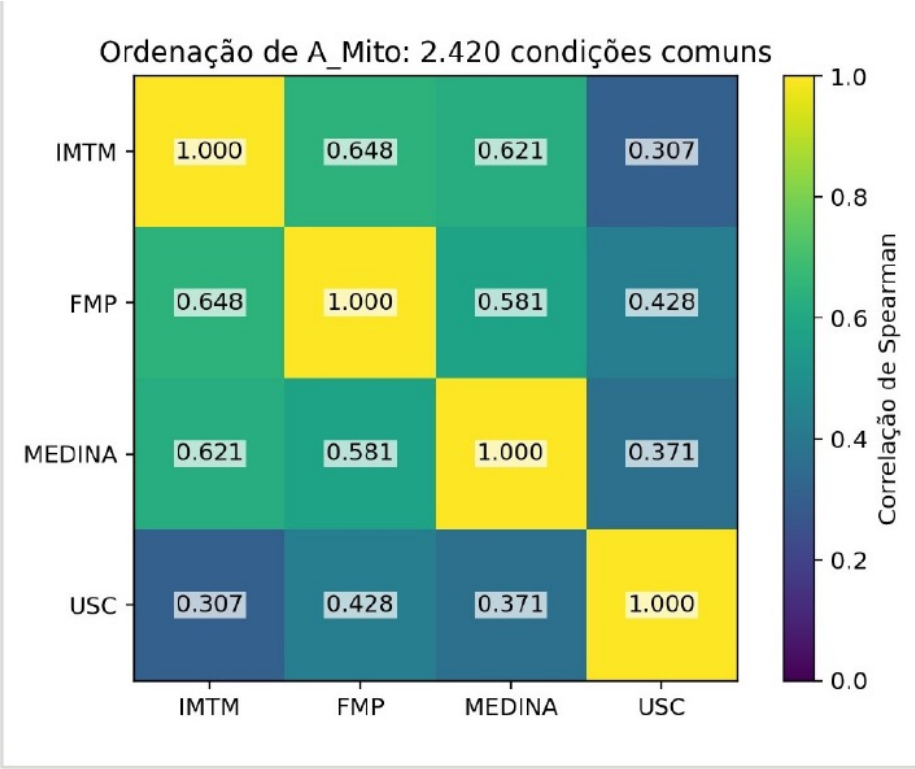
IMTM	FMP	MEDINA	USC
3 / 12	1 / 3	0 candidatos	28 / 71
25%	33%	—	39%

A pergunta binária e a pergunta contínua não são equivalentes.

R4 avaliou a estabilidade da regra congelada; não entrou na modelagem XGBoost.

A repetição parcial motivou separar duas questões:
reproduzir uma classificação e predizer a magnitude A_Mito.

Entre locais, a magnitude foi mais conservada do que a prioridade



2.420

condições comuns

539

A_Mito > 1 em todos os locais

1 **GLAUCINE**

prioridade em dois locais

Spearman de A_Mito entre locais: 0,31–0,65

Encontrar magnitude mitocondrial recorrente não significa conservar a mesma assinatura “predominante”.

XGBoost: o que entra, o que sai e como foi testado?

X características morfológicas da réplica de origem

XGBoost
relações não lineares

y log(1 + A_Mito) da outra réplica

6 direções entre R1–R3

R1→R2 R1→R3 R2→R1
R2→R3 R3→R1 R3→R2

5 folds externos por código EOS

todas as condições do mesmo composto ficam juntas em treino ou teste

R4 fica fora desta etapa

o teste é entre R1–R3, dentro de cada local

A pergunta mudou: não “volta a cruzar o limiar?”, mas “quanto da magnitude em outra réplica é previsível?”.

O XGBoost reduziu o erro nos quatro locais

IMTM

0,1172

MAE em log(1+A_Mito)

−10,5%

vs. copiar o escore

FMP

0,1280

MAE em log(1+A_Mito)

−14,7%

vs. copiar o escore

MEDINA

0,1438

MAE em log(1+A_Mito)

−16,7%

vs. copiar o escore

USC

0,1617

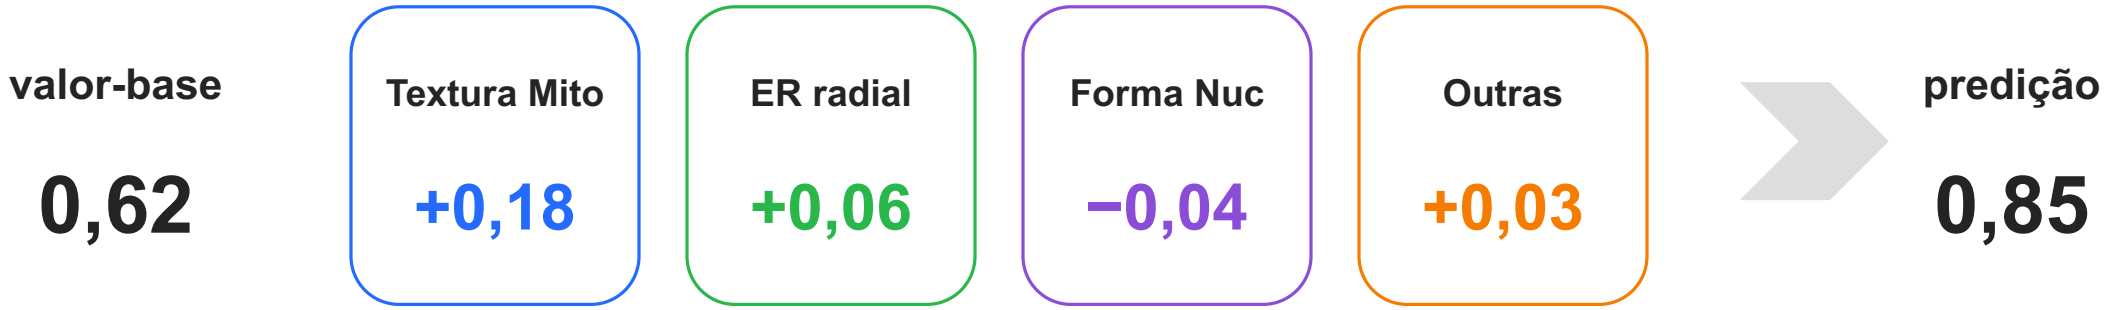
MAE em log(1+A_Mito)

−31,1%

vs. copiar o escore

A morfologia contém informação preditiva além de simplesmente copiar a magnitude da réplica de origem.

SHAP: quais características empurram a previsão para cima ou para baixo?

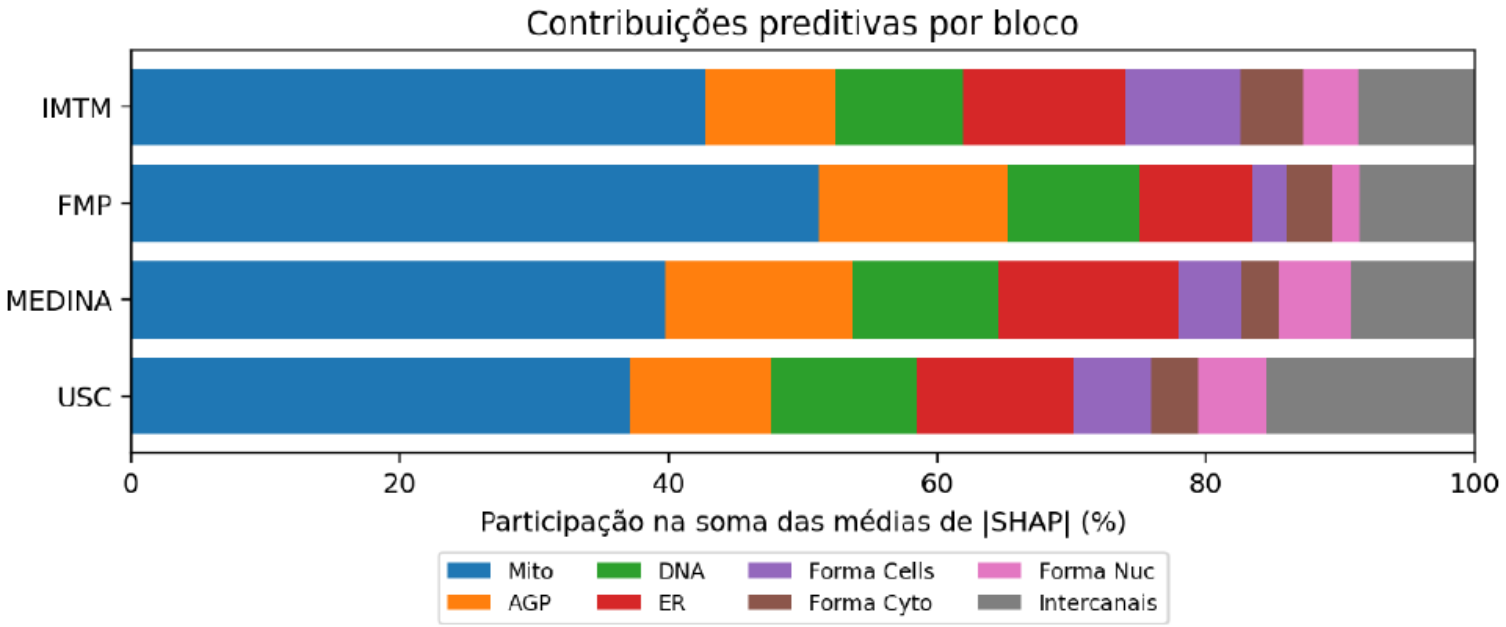


SHAP decompõe a estimativa do modelo em contribuições atribuídas às variáveis.

SHAP explica o modelo — não demonstra causalidade, função mitocondrial ou mecanismo de ação.

TCC: p. 10; 23–24

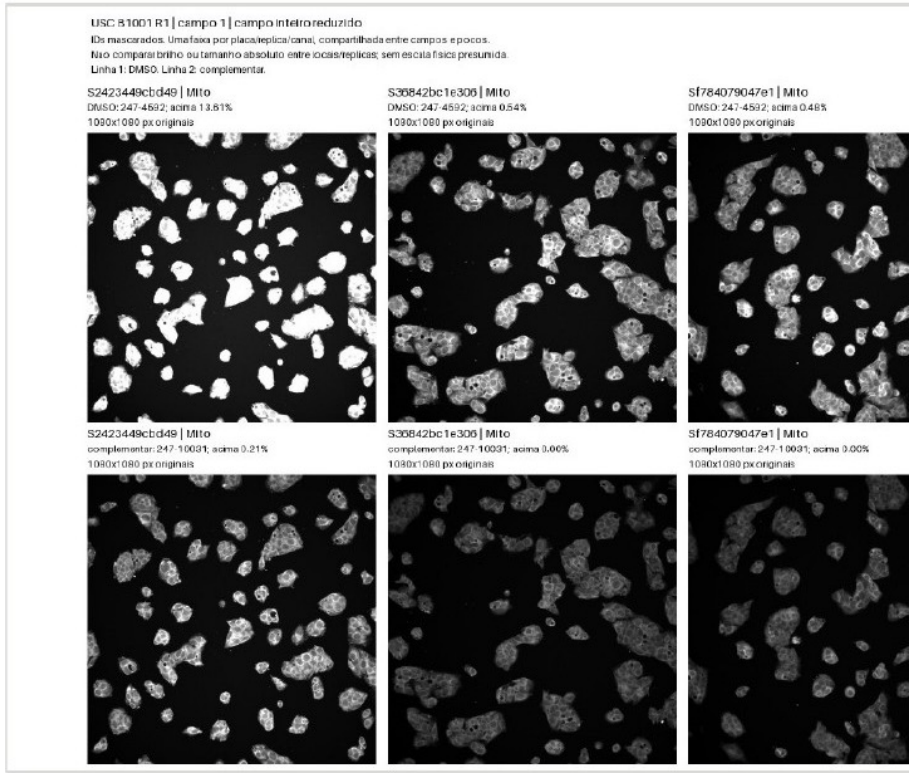
O modelo usou Mito como principal bloco — mas não sozinho



IMTM	42,69%
FMP	51,19%
MEDINA	39,77%
USC	37,15%

49–63% das atribuições vieram de outros blocos.

Alda-1: avaliação humana e o perfil nem sempre contam a mesma história



MEDINA R2 — **Sem diferença clara**

A_Mito 2,024 Intensidade 1,283× DMSO

USC R1 — **Visual variável**

A_Mito 1,096 Intensidade 1,733× DMSO

USC R3 — **Visual variável**

A_Mito 0,886 Intensidade 1,714× DMSO

Brilho visual ≠ magnitude multivariada: intensidade é uma medida; A_Mito resume muitas propriedades do perfil.

Resposta à pergunta biológica

539

magnitudes mitocondriais recorrentes

1

prioridade estrita compartilhada

0,117–0,162

MAE preditivo nos quatro locais

O que os dados sustentam

- magnitude repetível
- capacidade preditiva
- assinatura multibloco interpretável

O que não sustentam

- seletividade funcional
- mecanismo molecular
- generalização irrestrita entre locais

Referências principais

1. Chandrasekaran, S.N. et al. (2021). Image-based profiling for drug discovery: due for a machine-learning upgrade? Nature Reviews Drug Discovery, 20, 145–159.

2. Cimini, B.A. et al. (2023). Optimizing the Cell Painting assay for image-based profiling. Nature Protocols, 18, 1981–2013.

3. Chen, T.; Guestrin, C. (2016). XGBoost: a scalable tree boosting system. KDD 2016, 785–794.

4. Lundberg, S.M. et al. (2020). From local explanations to global understanding with explainable AI for trees. Nature Machine Intelligence, 2, 56–67.

5. Wolff, C. et al. (2025). Morphological profiling data resource enables prediction of chemical compound properties. iScience, 28, 112445.

6. Weisbart, E. et al. (2024). Cell Painting Gallery: an open resource for image-based profiling. Nature Methods, 21, 1775–1777.

Seleção das referências utilizadas no TCC; lista completa nas p. 30–31.

Obrigado!

Perguntas?